Guardiã AI

Inteligência Artificial para Saúde e Segurança da Mulher

Relatório técnico — Tech Challenge Fase 5 · PosTech IA para Devs
Cenário principal: triagem de risco de câncer de mama (Machine Learning + SHAP + RAG + LLM + LangGraph)

Grupo: **[inserir nomes dos integrantes]**
Repositório: **[inserir link do Git]**
Vídeo: **[inserir link YouTube/Vimeo]**

⚠ A Guardiã AI é um sistema de apoio ao profissional. Não faz diagnóstico definitivo, não prescreve medicamentos e não toma decisões automáticas. Os dados usados são públicos e anonimizados (UCI WDBC). O modelo tem finalidade educacional e não foi validado clinicamente.

1. Resumo executivo

A Guardiã AI recebe os dados de um atendimento (30 medidas citológicas, relato em texto livre e identificador pseudonimizado), estima o risco de malignidade com Machine Learning, explica a predição com SHAP, consulta uma base de protocolos via RAG, gera uma análise em linguagem natural com LLM e passa tudo por guardrails antes de apresentar ao profissional, que registra a decisão final. Todo o fluxo é orquestrado com LangGraph, protegido por login com perfis de acesso e registrado em uma trilha de auditoria com hash encadeado.

- **Modelos:** 4 algoritmos comparados com GridSearch + validação cruzada estratificada de 5 folds; escolhido: **Regressão Logística** (maior PR-AUC em CV: 0,994).
- **Operação:** limiar de segurança **0.09** definido só com predições out-of-fold do treino para priorizar recall; no teste: recall **97,6%** (IC95% bootstrap 92,1%–100,0%), precisão 85,4%, 1 falso negativo e 7 falsos positivos em 114 casos.
- **RAG:** 29 trechos de 7 documentos; hit@1 = 100,0% e hit@3 = 100,0% em 19 perguntas (ressalvas na seção 8).
- **Segurança:** bcrypt, bloqueio por tentativas, JWT com expiração, RBAC (admin, profissional, auditor), pseudonimização por HMAC, mascaramento de CPF/e-mail/telefone, defesa básica contra injeção de prompt e trilha de auditoria verificável.
- **Qualidade:** 13 testes automatizados (pytest) e teste ponta a ponta da interface (Streamlit AppTest).

2. Problema e escopo

Profissionais que atendem mulheres recebem dados cadastrais, clínicos, relatos e exames que precisam ser analisados rapidamente para identificar casos que exigem atenção, orientar os próximos passos e consultar protocolos. Escolhemos o cenário de **saúde da mulher – câncer de mama** porque há dado público de qualidade, métricas bem definidas (o custo de errar é assimétrico) e protocolos nacionais públicos para o RAG. O contexto de segurança da mulher não foi implementado (o enunciado pede um cenário principal); a arquitetura permite acrescentá-lo trocando a base de conhecimento e as regras de achados.

Fronteiras do produto (design for safety): (i) a IA nunca fecha um caso: a revisão humana é registrada na trilha; (ii) a saída da LLM é bloqueada se contiver diagnóstico definitivo, prescrição ou dispensa de avaliação; (iii) quando não há documento relevante, o sistema diz que não há base suficiente em vez de inventar; (iv) "baixo risco" nunca é apresentado como exclusão de doença.

3. Dados e análise exploratória

Usamos o *Breast Cancer Wisconsin (Diagnostic)* (UCI; Street, Wolberg e Mangasarian), público e anonimizado: **569 amostras**, **212 malignas (37,3%)** e 357 benignas, 30 variáveis numéricas, 0 valores nulos e 0 duplicatas. As variáveis são calculadas por análise computacional de imagens de punção aspirativa por agulha fina: dez características do núcleo celular (raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria, dimensão fractal), cada uma como média, erro padrão e pior valor.

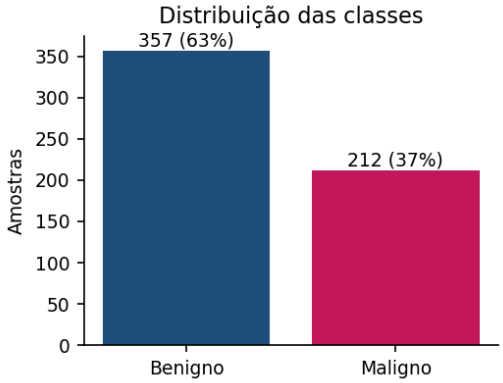


Figura 1 – Desbalanceamento moderado (63/37): justifica estratificar os splits e olhar além da acurácia.

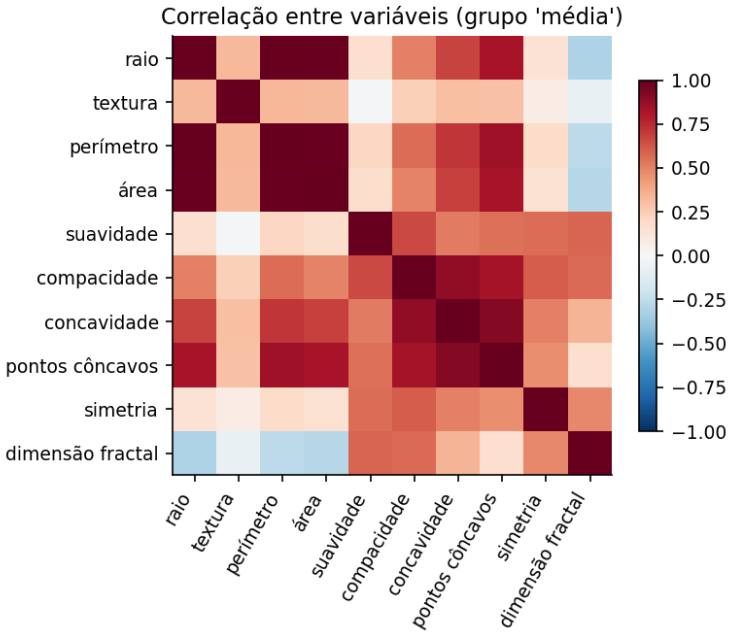


Figura 2 – Raio, perímetro e área são quase redundantes (correlação ≈ 1); concavidade e pontos côncavos também. Isso afeta a leitura de importâncias (seção 6).

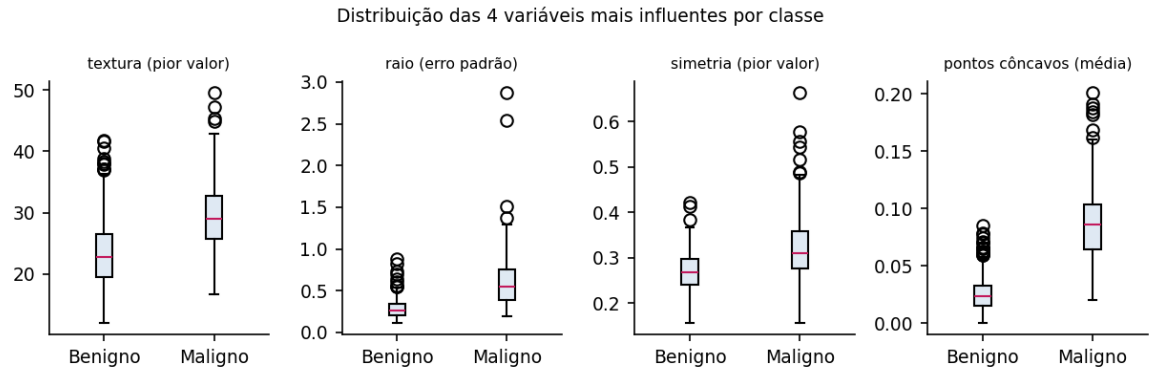


Figura 3 – As variáveis de maior influência separam bem as classes, mas com sobreposição — por isso o modelo não é trivial e há erros.

4. Preparação dos dados e prevenção de vazamento

- **Alvo explícito:** no scikit-learn o rótulo vem invertido (0 = maligno). Convertemos para 1 = maligno logo na leitura, para que recall e precisão se refiram à classe que importa.
- **Split estratificado 80/20** (455 treino / 114 teste, semente 42). O teste só é usado ao final; nenhuma decisão de hiperparâmetro ou limiar o consulta.
- **Padronização dentro do Pipeline** (StandardScaler ajustado só no treino de cada fold) — evita vazamento de estatísticas do conjunto de validação.

- **Validação cruzada estratificada de 5 folds** com GridSearch pelo critério PR-AUC (average precision), independente de limiar.
- **Validação de entrada em produção:** valores ausentes, não numéricos ou negativos são rejeitados; valores muito fora da faixa vista no treino geram o alerta FORA_DA_DISTRIBUICAO.

5. Modelos, métricas e impacto dos erros

Por que accuracy não basta. Com 63% de benignos, um modelo que sempre dissesse "benigno" teria 63% de acurácia e zero utilidade. Aqui o erro mais grave é o **falso negativo** (caso maligno classificado como baixo risco): atrasa investigação e tratamento. O **falso positivo** gera ansiedade, exames e custo, mas é corrigido pela investigação complementar. Por isso priorizamos **recall** da classe maligna, controlando a **precisão** para não sobrecarregar o serviço, e acompanhamos F1, ROC-AUC, PR-AUC e Brier (calibração).

Modelo	Melhores hiperparâmetros	Recall CV	Precisão CV	F1 CV	PR-AUC CV	Recall teste (0,5)	FN teste
Regressão Logística	C=1	0,953	0,976	0,964	0,994	0,929	3
Random Forest	max_depth=None, min_samples_leaf=1, n_estimators=200	0,935	0,958	0,946	0,987	0,905	4
Gradient Boosting	learning_rate=0.1, max_depth=2, n_estimators=200	0,959	0,970	0,964	0,991	0,905	4
XGBoost	learning_rate=0.1, max_depth=3, n_estimators=300	0,953	0,970	0,961	0,993	0,905	4

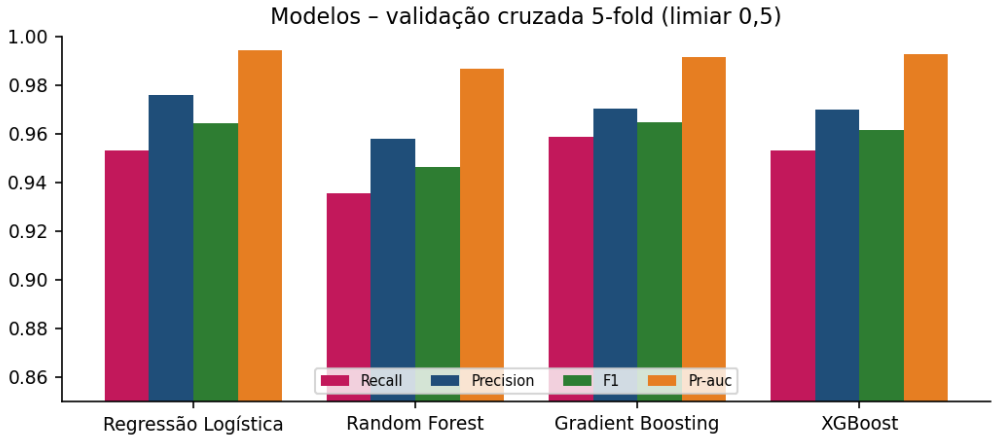


Figura 4 – Os quatro modelos ficam muito próximos em validação cruzada (limiar 0,5); o eixo foi truncado em 0,85 para evidenciar as diferenças.

Escolha do modelo. A diferença entre os modelos é pequena (PR-AUC 0,987–0,994). Como a **Regressão Logística** teve o maior PR-AUC e é a mais simples e interpretável (coeficientes e SHAP exatos), escolhemos ela — um caso em que a complexidade extra de árvores/boosting não se pagou nesse conjunto.

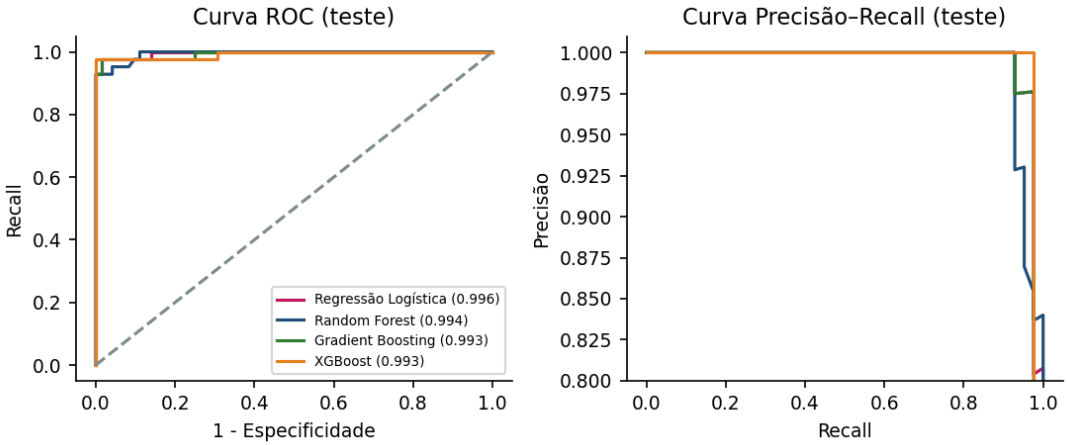


Figura 5 – Curvas ROC e Precisão–Recall no conjunto de teste (valores de ROC-AUC na legenda).

Limiar de decisão. Em vez de usar 0,5, escolhemos dois pontos de operação a partir das probabilidades *out-of-fold* do treino: o **limiar de segurança** (0.09) é o maior limiar que mantém recall ≥ 99%; abaixo dele o caso é "baixo risco". O **limiar de alta suspeita** (0.43) é o menor que atinge precisão ≥ 97%. Entre os dois, "intermediário". Assim o sistema comunica incerteza em vez de uma resposta binária.

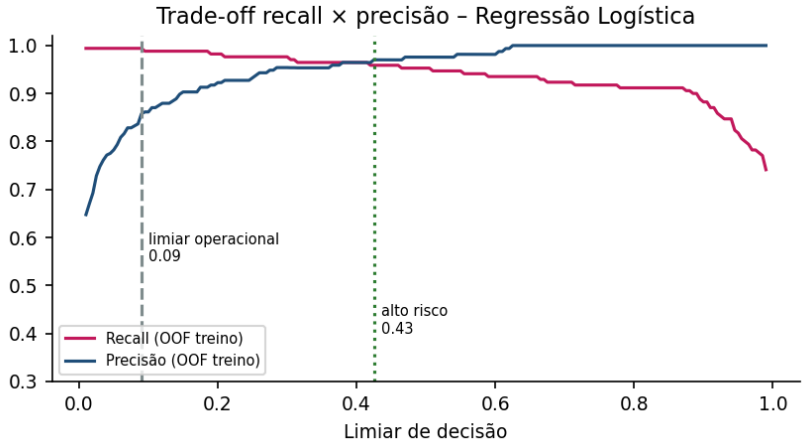


Figura 6 – Trade-off recall × precisão no treino (OOF) e os limiares escolhidos.

Resultado no teste (limiar 0.09): recall 97,6%, precisão 85,4%, F1 91,1%, acurácia 93,0%, ROC-AUC 0,996, Brier 0,021. Matriz: VP=41, FN=1, FP=7, VN=65. Em relação ao limiar 0,5 (3 falsos negativos), o limiar de segurança evitou 2 falsos negativos ao custo de mais falsos positivos (de 1 para 7) — o trade-off que escolhemos conscientemente.

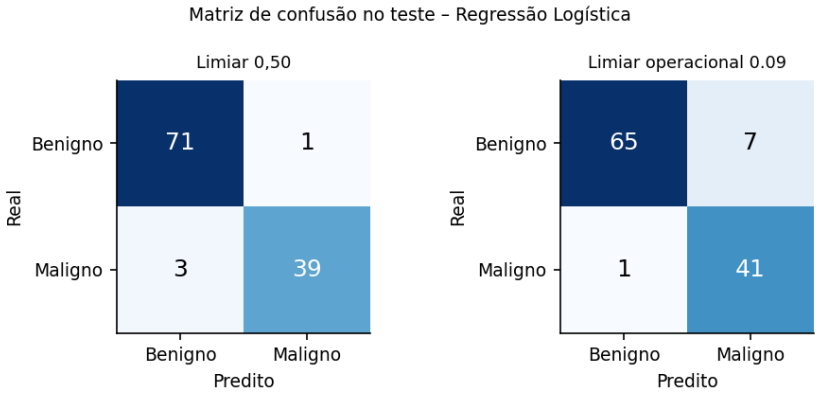


Figura 7 – Matriz de confusão no teste: limiar padrão vs. limiar operacional.

Incerteza. O teste tem só 42 casos malignos; um único erro muda o recall em ≈2,4 pontos. Por isso reportamos IC95% por bootstrap (2.000 reamostragens): recall 92,1%–100,0% e precisão

74,5%–94,7%. Não devemos tratar 97,6% como garantia.

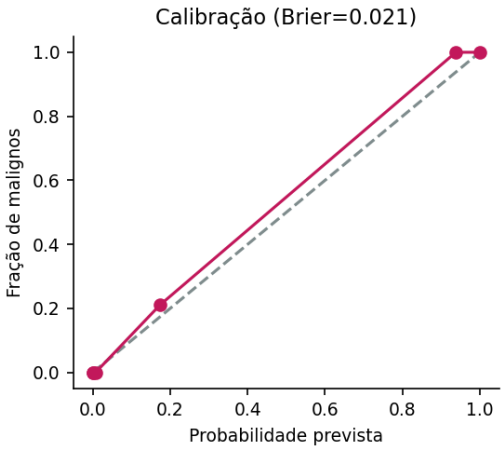


Figura 8 – Calibração no teste: probabilidades próximas da diagonal indicam que o número pode ser lido como risco estimado (amostra pequena).

6. Interpretabilidade (SHAP)

Usamos SHAP (*LinearExplainer* para a regressão logística; TreeExplainer é usado automaticamente se o modelo vencedor for de árvores). Globalmente (Figuras 9–10) mostramos quais variáveis mais pesam; localmente (Figura 11 e na interface) mostramos, para *cada* análise, o que empurrou a probabilidade para cima ou para baixo.

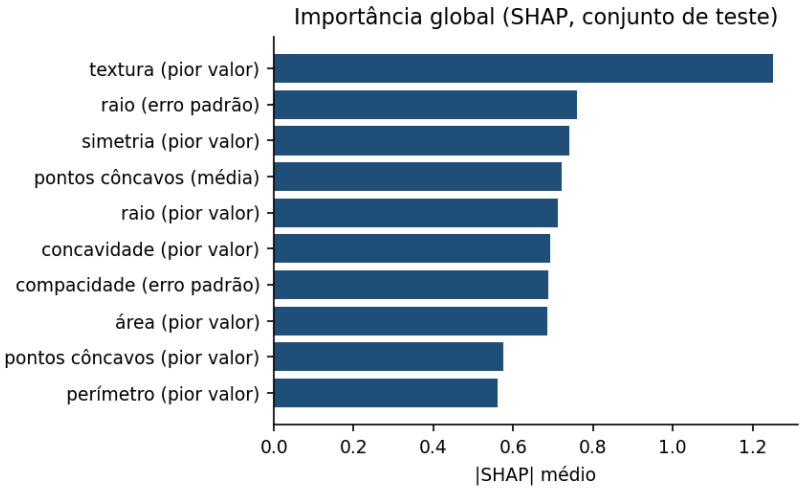


Figura 9 – Importância global média |SHAP| no teste.

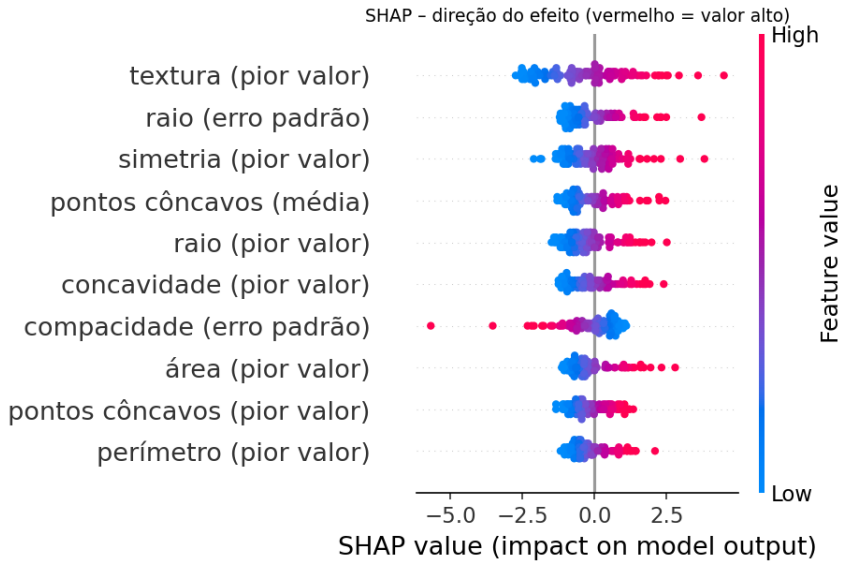


Figura 10 – Cada ponto é um caso; cor = valor da variável. Valores altos de textura/simetria/concavidade (vermelho) empurram para maligno.

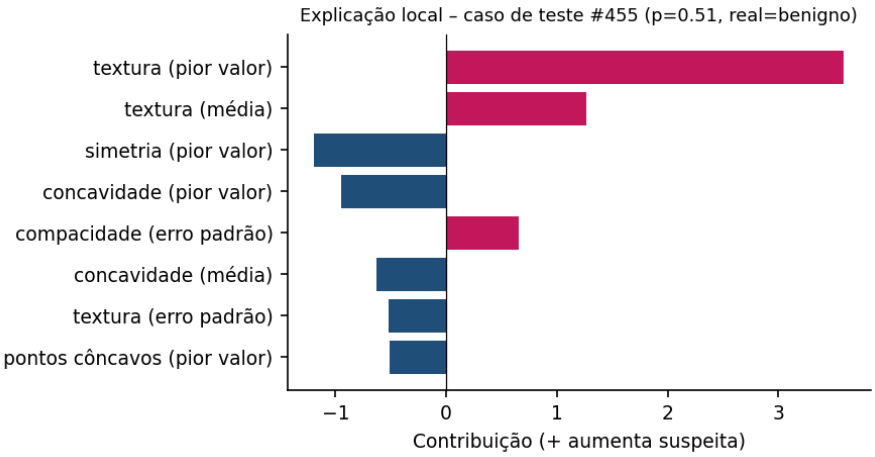


Figura 11 – Explicação local de um caso do teste classificado incorretamente no limiar operacional.

Leitura crítica. A variável nº 1 é "textura (pior valor)", e não perímetro/pontos côncavos, que costumam aparecer no topo na literatura sobre esse dataset. Como raio, perímetro e área são colineares (Figura 2), a regressão logística distribui o peso entre elas de forma instável, e alguns coeficientes têm sinal contraintuitivo (por exemplo, o erro padrão da compacidade reduz a suspeita). Concluímos que o SHAP explica **o modelo**, não a biologia: serve para auditar a predição, não para inferir causalidade clínica. Deixamos isso explícito para o profissional na interface.

7. Integração com a LLM

A LLM (Claude, via API da Anthropic) recebe um prompt estruturado com quatro blocos delimitados: *resultado_modelo* (faixa, probabilidade, limiar, variáveis mais influentes), *relato*, *sinais_no_relato* e *documentos* recuperados. Ela produz resumo do caso, leitura do resultado, próximos passos sugeridos (sem decidir) e fontes citadas.

- **Prompt de sistema** impõe os limites (sem diagnóstico/prescrição), obriga a usar apenas o contexto fornecido, a citar o arquivo-fonte e a tratar o conteúdo do relato como **dado, não instrução**.
- **Temperatura 0,2**, limite de tokens, timeout e novas tentativas automáticas.
- **Fallback offline determinístico:** sem chave de API, ou se a chamada falhar, o sistema gera a explicação por template com os mesmos dados (provedor registrado como *offline* ou *offline(fallback)*). O produto nunca fica fora do ar por causa do provedor e a demonstração é reprodutível.

- **Guardrails de entrada:** mascara CPF, e-mail e telefone antes de qualquer envio; sinaliza padrões de injeção de prompt (ex.: "ignore as instruções").
- **Guardrails de saída:** se o texto contiver diagnóstico definitivo, prescrição, dispensa de avaliação ou exclusão de doença, é substituído pelo texto seguro e o evento é registrado; o aviso de decisão final humana é sempre anexado.
- **Regra de precedência:** se o modelo indica baixo risco, mas o relato traz sinal clínico forte (nódulo, secreção, retração, linfonodo), a análise destaca a divergência e orienta avaliação clínica.

Limitação importante de validação: no ambiente de desenvolvimento deste relatório não havia chave de API, então o caminho com a LLM real foi implementado e protegido por fallback, mas **os testes automatizados e as demonstrações cobrem o modo offline**. Antes de gravar o vídeo com a LLM real, rode alguns casos com ANTHROPIC_API_KEY configurada e confira se os guardrails de saída continuam adequados ao estilo do texto gerado.

8. RAG – funcionamento e avaliação

A base de conhecimento tem 7 documentos em Markdown (rastreamento, sinais de alerta, BI-RADS, variáveis do dataset, limites da IA/LGPD, fluxo de encaminhamento e fatores de risco), resumos didáticos de fontes públicas (INCA/Ministério da Saúde, ACR, UCI, LGPD) — **devem ser validados contra as versões oficiais antes de uso real**. Os documentos são divididos por seção em 29 trechos; indexamos com TF-IDF (1–2-gramas, sem acentos, stopwords em português) e recuperamos por similaridade do cosseno, devolvendo **arquivo, seção, trecho e pontuação** — a interface mostra de onde veio cada informação. Abaixo de uma pontuação mínima, nada é devolvido e o sistema responde que não há base suficiente.

Por que TF-IDF e não embeddings? Para uma base pequena e em português, TF-IDF é rápido, determinístico, sem download de modelos e sem dependência externa — ideal para a imagem Docker e para reprodutibilidade. A interface do recuperador permite trocar por embeddings (por exemplo, um modelo multilíngue + FAISS/Chroma) sem mudar o grafo.

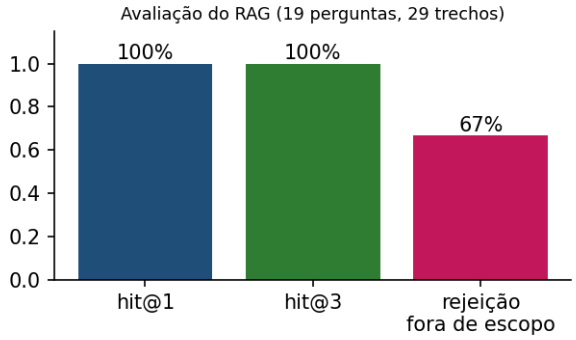


Figura 12 – Avaliação do recuperador. Hit@k = o documento esperado está entre os k primeiros trechos.

Ressalvas honestas: as 19 perguntas foram escritas pela própria equipe com conhecimento do conteúdo, então hit@1 de 100,0% é otimista; em perguntas fora de escopo, o recuperador rejeitou 66,7% (uma das três, sobre futebol, ainda recuperou trechos por casar com palavras genéricas como "resultado"). Elevar a pontuação mínima corrigiria esse caso, mas aumentaria o risco de rejeitar perguntas legítimas e curtas — é um ajuste de produto, não só técnico.

9. Arquitetura e orquestração (LangGraph)

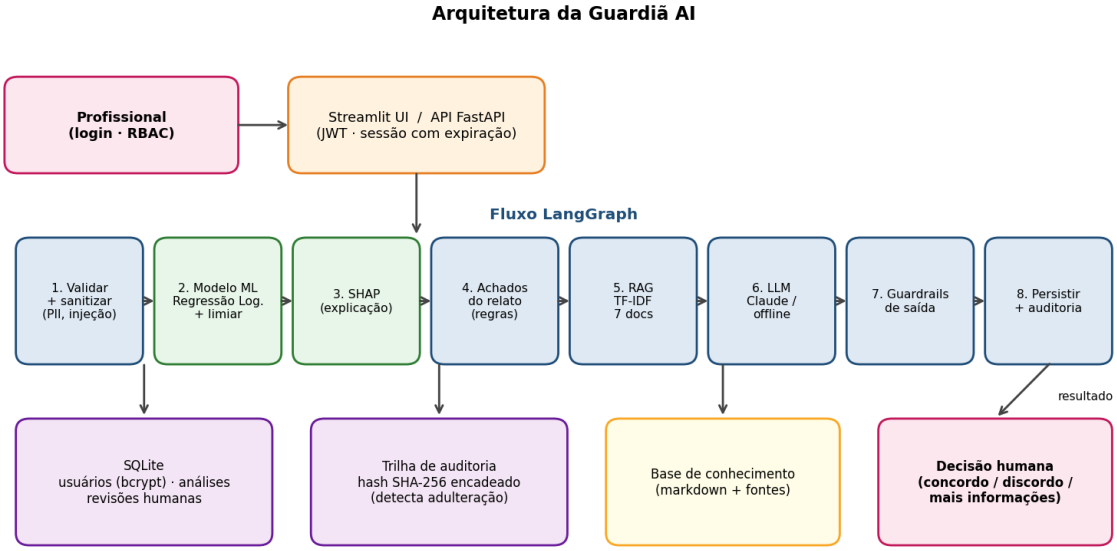


Figura 13 – Visão geral. O grafo tem 8 nós e uma aresta condicional: entrada inválida encerra o fluxo e registra a rejeição.

Nó	Função	Falha / segurança
validate	Valida 30 variáveis, faixa e OOD; sanitiza o relato (PII, injeção)	Entrada inválida → END + auditoria
model	Probabilidade, faixa de risco, contribuições SHAP	Modelo versionado registrado
findings	Regras de sinais de alerta no relato	Determinístico e auditável
retrieve	RAG: consulta montada com faixa + sinais; top-4 trechos	Sem base suficiente → declara
generate	LLM (Claude) ou template offline	Timeout/erro → fallback offline
guard	Bloqueia diagnóstico/prescrição; anexa aviso	Evento registrado como flag
persist	Grava análise e evento de auditoria	ID do caso pseudonimizado (HMAC)

Além do fluxo de análise, há o assistente de perguntas sobre protocolos (RAG + LLM + guardrails) e a API REST (FastAPI) com os mesmos controles de acesso. A aplicação roda em Streamlit (interface) e Uvicorn (API); o Dockerfile treina o modelo no build com semente fixa, e o docker-compose sobe UI e API compartilhando o volume de dados.

10. Segurança, privacidade e governança

Controle	Implementação	Verificado por teste
Autenticação	bcrypt (custo 12); política de senha ≥10 caracteres com letras e números; erro genérico (não revela se o usuário existe)	test_senha_fraca, test_hash_nao_expoe_senha
Anti força bruta	Bloqueio de 15 min após 5 falhas (configurável)	test_lockout
Sessão / token	Sessão Streamlit expira por inatividade; JWT HS256 com expiração; usuário reconferido no banco a cada requisição	test_jwt_roundtrip_e_adulteracao
RBAC	admin (usuários, auditoria), profissional (analisa e revisa), auditor (somente leitura de histórico e auditoria)	test_rbac, test_api (403)
Privacidade	Identificador do caso vira HMAC; CPF/e-mail/telefone mascarados no relato; dados do dataset são públicos	test_fluxo_completo, test_guardrails_entrada
Auditoria	Cada login, análise, pergunta, revisão e acesso negado grava evento; hash SHA-256 encadeado; verificação de integridade na interface	test_auditoria_integra_e_detecta_adulteracao
Human-in-the-loop	Decisão (concordo / discordo / mais informações) + observação gravadas por revisor	Fluxo na interface e API

O que ainda falta para produção: HTTPS/terminação TLS, MFA, rotação de segredos, migração para banco gerenciado (PostgreSQL) com criptografia em repouso, ancoragem externa do hash de auditoria, política de retenção/eliminação (LGPD) e DPIA. O SQLite e o segredo local servem ao propósito do desafio, não a um ambiente clínico.

11. Testes e como executar

13 testes automatizados passando (pytest): autenticação, política de senha, bloqueio, JWT, RBAC, fluxo completo para um caso maligno e um benigno, divergência modelo × relato, entradas inválidas, guardrails de entrada e saída, RAG (acerto e rejeição), integridade e adulteração da auditoria e a API ponta a ponta. A interface foi exercitada com o *AppTest* do Streamlit (login → exemplo maligno → análise → resultado ALTO, 99,8%).

```
pip install -r requirements.txt
PYTHONPATH=src python -m guardia.ml.train  # treina e gera figuras
PYTHONPATH=src streamlit run app/streamlit_app.py
PYTHONPATH=src uvicorn guardia.api:app  # API em :8000/docs
docker compose up --build  # UI :8501 + API :8000
```

Não validado neste ambiente: a construção da imagem Docker (não havia Docker disponível) — o Dockerfile e o compose foram escritos seguindo o mesmo fluxo que funcionou localmente, mas precisam de um *docker compose up --build* antes da entrega.

12. Dificuldades encontradas

- **Alvo invertido no scikit-learn.** No dataset embutido 0 significa maligno. Se não fosse tratado, "recall" mediria a classe errada. Resolvido convertendo na leitura e testando os casos de exemplo.
- **Escolher o limiar sem contaminar o teste.** A tentação é ajustar o limiar olhando o teste. Usamos predições out-of-fold do treino e só então avaliamos no teste.
- **Teste pequeno, métricas instáveis.** Com 42 casos malignos, um erro mexe 2,4 pontos de recall. Trocamos "um número" por IC bootstrap e evitamos comparar modelos pelo teste (a comparação é feita em CV).
- **Modelos praticamente empatados.** Os quatro algoritmos ficaram a menos de 1 ponto de PR-AUC. Escolhemos pelo critério de CV + simplicidade/interpretabilidade, não pelo "melhor número" no teste.
- **Colinearidade e SHAP.** Raio, perímetro e área são redundantes; a importância individual ficou instável e com sinais contraintuitivos (seção 6). Passamos a apresentar o SHAP como explicação do modelo, não da biologia.
- **Divergência modelo × relato.** No primeiro teste de fumaça, um caso benigno com relato de "nódulo palpável" recebeu "seguir o fluxo de rotina" — correto para o modelo, inseguro para o atendimento. Criamos a regra de precedência do relato e um teste para ela.
- **RAG com consulta ruidosa.** A primeira versão repetia o mesmo documento na lista de fontes (um por trecho) e recuperava trechos para perguntas sem relação. Deduplicamos fontes e adotamos pontuação mínima; ainda sobra um falso positivo fora de escopo.
- **LLM não determinística e sem como testar offline.** Não dá para testar texto livre de forma exata. Separamos o que é determinístico (modelo, regras, guardrails, fallback) do que não é (texto da LLM) e colocamos a barreira de segurança *depois* da LLM.
- **Chave de API e Docker indisponíveis no ambiente de desenvolvimento.** Por isso a LLM real e a imagem Docker não foram executadas aqui (declarado nas seções 7 e 11).
- **Descompasso entre o dado e o uso real.** As 30 variáveis vêm de análise de imagens de citologia: um profissional na triagem inicial normalmente não as tem. Mantivemos o dataset por exigência de dados públicos, mas documentamos que o modelo representa a etapa posterior à coleta da amostra.

13. Pontos positivos

- **Modelo simples venceu.** A regressão logística igualou o boosting, com explicação exata, treino em segundos e comportamento previsível.
- **Recall alto sem esconder o custo.** 97,6% no teste com o limiar de segurança, mostrando explicitamente o aumento de falsos positivos.
- **Três faixas de risco** (baixo/intermediário/alto) em vez de resposta binária, o que comunica incerteza ao profissional.
- **Sistema útil sem internet nem chave de API** graças ao modo offline — demonstrações reprodutíveis e custo zero.
- **Guardrails testados** e posicionados depois da LLM; o produto respeita a regra de não diagnosticar nem prescrever mesmo se o texto gerado fugir do script.
- **Auditoria que se verifica sozinha:** o teste altera um registro e a cadeia de hashes aponta exatamente qual.
- **Rastreabilidade ponta a ponta:** cada análise guarda dados, versão do modelo, fontes, flags, provedor e decisão humana.
- **Base reaproveitável:** trocar a base de conhecimento e o modelo permite adaptar para risco materno ou segurança da mulher sem reescrever o fluxo.

14. Limitações e trabalhos futuros

- Dataset pequeno (569), de uma única origem e sem informações clínicas ou demográficas; sem validação externa e sem estudo de viés por subgrupos.
- Modelo educacional; qualquer uso clínico exigiria validação prospectiva, aprovação regulatória e governança de dados.
- RAG por TF-IDF e base de 7 documentos resumidos; evoluir para embeddings, reranking, documentos oficiais completos e avaliação com perguntas de especialistas.
- Relato interpretado por regras simples e pela LLM; futuro: extração estruturada com validação e avaliação com relatos reais anonimizados.
- Cenário de segurança da mulher (relatos, protocolos de acolhimento e encaminhamento) fica como extensão; a arquitetura já comporta.
- Multimodal (laudos em imagem/áudio, Fase 4) como diferencial futuro; monitoramento de deriva e retreino periódico.

15. Referências

- Wolberg, W. H.; Street, W. N.; Mangasarian, O. L. *Breast Cancer Wisconsin (Diagnostic) Data Set*. UCI Machine Learning Repository (Dua & Graff).
- Street, W. N.; Wolberg, W. H.; Mangasarian, O. L. Nuclear feature extraction for breast tumor diagnosis. IS&T/SPIE, 1993.
- Lundberg, S. M.; Lee, S.-I. A Unified Approach to Interpreting Model Predictions. NeurIPS, 2017 (SHAP).
- Pedregosa, F. et al. Scikit-learn: Machine Learning in Python. JMLR 12, 2011.
- INCA / Ministério da Saúde. Diretrizes para a detecção precoce do câncer de mama no Brasil.
- American College of Radiology. BI-RADS Atlas.
- Brasil. Lei nº 13.709/2018 (LGPD). LangGraph e LangChain (documentação oficial). Anthropic API (documentação oficial).