

TECH CHALLENGE 05

IA para Devs

FIAP 2026

GRUPO 33

TECH CHALLENGE

Grupo 33

Integrantes do Grupo 33

Cesar Melo Dutra - cesar.dutra@pcdf.df.gov.br – rm370002

Fernando Ramos Etchepare - fernando.etchepare@pcdf.df.gov.br – rm370000

Vídeo Youtube público: https://youtu.be/PHROqxmKAtw



Use a câmera do seu celular ou

acesse a página Git
https://github.com/fetchepare/FIAP

DESAFIO

Guardiã AI — Inteligência Artificial para Saúde e Segurança da Mulher

Uma instituição que atua no acolhimento e assistência à mulher busca aprimorar seus fluxos de atendimento utilizando Inteligência Artificial. Durante a jornada de atendimento, são recebidos múltiplos tipos de dados sensíveis: cadastros, sintomas clínicos, dados de exames citológicos e laboratoriais, respostas a formulários, relatos escritos e histórico pregresso. Essas informações demandam triagem rápida e precisa por parte dos profissionais para priorizar casos graves, orientar condutas imediatas e consultar protocolos oficiais de referência.

O desafio proposto para a Fase 5 consiste em desenvolver a Guardiã AI, uma solução tecnológica robusta capaz de receber dados clínicos e relatos de atendimento, empregando diferentes técnicas de Inteligência Artificial para apoiar a análise inicial do caso.

O desafio estabelece a atuação em dois contextos essenciais: saúde da mulher e segurança da mulher.

Cenário Principal Escolhido pelo Grupo:
O grupo selecionou como cenário principal o Apoio à Triagem e Estratificação de Risco de Câncer de Mama (contexto de Saúde da Mulher), integrando o processamento de relatos clínicos com sanitização e mascaramento de dados sensíveis (LGPD) e identificação de sinais de alerta (contexto de Segurança da Mulher). A solução combina Machine Learning com calibração de limiar seguro focado em Recall, explicabilidade diagnóstica por SHAP, consulta automatizada a protocolos clínicos oficiais (RAG), síntese em linguagem natural via LLM, guardrails de segurança e homologação obrigatória da decisão médica pelo profissional responsável.

OBJETIVO

Desenvolver e disponibilizar um produto completo de Inteligência Artificial para suporte à triagem clínica de câncer de mama, demonstrando uma jornada ponta a ponta funcional, segura e responsável.

Fluxo Operacional da Solução:
A aplicação implementa o fluxo completo exigido pelo desafio: Entrada dos dados (citologia PAAF e relato) → Validação e sanitização (LGPD e injeção de prompt) → Predição por Machine Learning → Interpretabilidade com SHAP → Extração de achados e sinais de alerta → Consulta a protocolos oficiais (RAG) → Interpretação contextualizada por LLM → Guardrails de saída → Apresentação na interface web → Homologação da Decisão Médica Final (Human-in-the-Loop) → Persistência em Trilha de Auditoria Encadeada com SHA-256.

Diretrizes Mandatórias de Governança e Ética Médica:
• "A decisão final sempre deverá permanecer com uma pessoa responsável pelo atendimento."
• A Guardiã AI funciona estritamente como um sistema de apoio ao profissional, e não como substituição da decisão humana.
• A aplicação não realiza diagnóstico médico definitivo, não prescreve medicamentos e não toma decisões clínicas de forma automática.
• Todas as ações, estimativas, consultas ao RAG e decisões médicas são imutavelmente registradas em trilha de auditoria encadeada (SHA-256).

ENTREGÁVEIS

Repositório Git: https://github.com/fetchepare/FIAP

Relatório técnico com:

● Problema Escolhido e Escopo Clínico: Justificativa do cenário de triagem de câncer de mama, contexto epidemiológico e fronteiras éticas do produto (design for safety);
● Conjunto de Dados e Análise Exploratória: Exploração detalhada do dataset público e anonimizado UCI WDBC (Wisconsin Diagnostic Breast Cancer) com 569 casos e 30 atributos morfológicos celulares nucleares de punção aspirativa por agulha fina (PAAF);
● Preparação dos Dados e Prevenção de Vazamento: Divisão estratificada 80/20 (455 treino / 114 teste), padronização ajustada exclusivamente no conjunto de treino e validação cruzada estratificada de 5 folds;
● Modelos de Machine Learning e Comparativo: Treinamento, otimização

(GridSearchCV) e comparação de 4 algoritmos: Regressão Logística, Random Forest, Gradient Boosting e XGBoost;
● Métricas e Impacto Clínico dos Erros: Avaliação via Accuracy, Precision, Recall, F1-Score, ROC-AUC, PR-AUC e Brier Score, com calibração de limiar seguro de operação (t_low = 0,09) priorizando alto Recall para mitigar falsos negativos;
● Interpretabilidade e Explicabilidade com SHAP: Aplicação de valores de Shapley locais e globais, detalhando as variáveis celulares que mais aumentam ou reduzem a suspeita clínica;
● Integração com LLM e Guardrails: Uso de modelo de linguagem (Claude 3.5 Sonnet / Anthropic com fallback determinístico offline) para síntese clara em linguagem natural, com bloqueio estrito de prescrições e diagnósticos definitivos;
● RAG (Retrieval-Augmented Generation): Base de conhecimento com 7 documentos oficiais (INCA, Ministério da Saúde, BI-RADS e fluxos SUS), com recuperação por TF-IDF e cosseno (Hit@1 = 100%, Hit@3 = 100%);
● Arquitetura e Orquestração: Grafo de estados implementado com LangGraph (8 etapas), interface web em Streamlit e API RESTful em FastAPI;
● Governança, LGPD e Auditoria: Mascaramento de dados pessoais (CPF, e-mail, telefone), proteção contra injeção de prompt, controle de acesso RBAC e trilha de auditoria encadeada com hash SHA-256;
● Limitações e Responsabilidade Médica: Análise das limitações amostrais e reafirmação do compromisso de que a decisão final sempre deverá permanecer com o profissional de saúde responsável.

Vídeo com até 15 minutos demonstrando:

● Upload no YouTube ou Vimeo (público ou não listado);

● Apresentação conceitual do problema e justificativa clínica da triagem de câncer de mama na saúde da mulher;
● Demonstração prática da aplicação funcionando de ponta a ponta na interface web interativa (Streamlit);
● Jornada completa de atendimento: login com controle de acesso RBAC, inserção de medidas citológicas reais (WDBC) e relato clínico livre;
● Mecanismos de segurança em tempo real: mascaramento automático de dados sensíveis (CPF, e-mail, telefone) e detecção de sinais de alerta (red flags);
● Execução do modelo de Machine Learning, calibração do limiar operacional e explicabilidade visual por valores SHAP;
● Consulta interativa ao assistente RAG sobre protocolos oficiais de conduta (classificação BI-RADS e fluxos SUS), com citação de fontes;
● Geração de síntese explicativa em linguagem natural pela LLM contextualizada

com as evidências do caso;

● Homologação da Decisão Médica Final pelo profissional responsável, com inclusão de CRM, conduta clínica e termo de responsabilidade soberana;

● Módulo de governança: visualização do histórico e comprovação da integridade da trilha de auditoria encadeada (SHA-256 estilo blockchain);

● Demonstração da API REST (FastAPI) e execução da suíte de testes automatizados (pytest com 14 testes aprovados).

LINKS

- Página GIT: https://github.com/fetchepare/FIAP
  - Código Fonte Completo: techchallenge05.zip
  - Relatório Técnico (estratégias, modelos, resultados e interpretação): TechChallenge05.PDF (este arquivo)
- Vídeo: https://youtu.be/yfoI5iDFnBE

RELATÓRIO TÉCNICO

Relatório Técnico — Tech Challenge Fase 5

Sistema Guardiã AI — Triagem e Estratificação de Risco de Câncer de Mama

Este relatório técnico detalha a especificação da solução de Inteligência Artificial Guardiã AI, desenvolvida para apoio a profissionais de saúde na triagem e estratificação de risco de câncer de mama. A plataforma combina dados citológicos reais (UCI WDBC), modelos de Machine Learning otimizados com foco em sensibilidade (Recall), explicabilidade clínica por SHAP, Large Language Model (LLM), recuperação de diretrizes clínicas oficiais por RAG, governança robusta com trilha de auditoria encadeada e a garantia de que a decisão final sempre deverá permanecer com uma pessoa responsável pelo atendimento.

---

1. Resumo Executivo e Problema Clínico

O câncer de mama é a neoplasia maligna mais frequente e a principal causa de mortalidade por câncer entre mulheres no Brasil e no mundo. O prognóstico está diretamente associado à precocidade do diagnóstico: tumores diagnosticados em estágios iniciais alcançam taxas de cura superiores a 90%, ao passo que atrasos no encaminhamento clínico elevam os custos assistenciais e reduzem severamente a sobrevida das pacientes.

Nos serviços de acolhimento e triagem, os profissionais de saúde enfrentam o desafio de analisar simultaneamente relatos clínicos de anamnese, histórico de fatores de risco e laudos morfológicos de exames de biópsia por punção aspirativa por agulha fina (PAAF). A Guardiã AI foi desenvolvida precisamente para atuar como ferramenta de apoio à decisão nesse ponto crítico do fluxo assistencial.

Fronteiras de Segurança do Produto (Design for Safety): A Guardiã AI opera sob premissas rigorosas: (i) a IA nunca fecha um caso de forma autônoma; (ii) o sistema não emite diagnóstico definitivo nem prescreve medicamentos; (iii) a decisão clínica final e a conduta terapêutica permanecem obrigatoriamente sob a responsabilidade exclusiva do profissional de atendimento.

2. Conjunto de Dados (UCI WDBC) e Análise Exploratória

A modelagem preditiva utiliza o dataset público e anonimizado Wisconsin Diagnostic Breast Cancer (WDBC), disponibilizado pelo repositório UCI Machine Learning. O dataset compreende 569 casos clínicos, sendo 357 benignos (62,7%) e 212 malignos (37,3%).

Cada registro é composto por 30 variáveis contínuas que descrevem as propriedades geométricas e de textura dos núcleos celulares observados em lâminas de PAAF digitalizadas. Os atributos derivam de 10 características morfológicas fundamentais: raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria e dimensão fractal.

Para cada núcleo celular, são calculadas três medidas estatísticas: a média (mean), o erro padrão (standard error - se) e o pior valor observado (worst), totalizando os 30 atributos. A análise exploratória evidenciou forte correlação positiva com malignidade nas variáveis associadas à dimensão celular (worst perimeter, worst radius, worst area) e às reentrâncias da membrana nuclear (worst concave points).

3. Preparação dos Dados e Prevenção de Vazamento (Data Leakage)

Para garantir validade metodológica e prevenir vazamento de dados (data leakage), o dataset foi dividido em 80% para treinamento (455 amostras) e 20% para teste final cego (114 amostras), com estratificação pela classe de malignidade e semente aleatória fixa (seed=42).

O conjunto de teste cego foi mantido estritamente isolado durante todas as etapas de calibração, seleção de modelos e ajuste de hiperparâmetros. Todas as transformações de pré-processamento (padronização StandardScaler e imputação de valores faltantes) foram ajustadas exclusivamente nos dados de treino e apenas aplicadas ao conjunto de teste.

A validação interna dos modelos utilizou validação cruzada estratificada de 5 folds (StratifiedKFold) com otimização exaustiva de hiperparâmetros via GridSearchCV, assegurando estimativas de desempenho robustas e reprodutíveis.

4. Modelos de Machine Learning e Comparativo de Desempenho

Foram treinados e comparados quatro algoritmos representativos de diferentes famílias de aprendizado supervisionado: Regressão Logística (linear calibrada), Random Forest (ensemble bagging), Gradient Boosting (boosting sequencial) e XGBoost (gradient boosting com regularização de segunda ordem).

Resultados comparativos na validação cruzada (CV 5-fold, média ± desvio-padrão):

• Regressão Logística: Accuracy = 97,4% | Recall = 95,3% | F1-Score = 96,4% | ROC-

AUC = 0,995
• Gradient Boosting: Accuracy = 97,4% | Recall = 95,9% | F1-Score = 96,4% | ROC-AUC = 0,993
• XGBoost: Accuracy = 97,1% | Recall = 95,3% | F1-Score = 96,1% | ROC-AUC = 0,994
• Random Forest: Accuracy = 96,0% | Recall = 93,5% | F1-Score = 94,6% | ROC-AUC = 0,989

Modelo Selecionado para Produção: A Regressão Logística (penalização L2, C=0.1, solver lbfgs) foi escolhida como o modelo principal da solução. As razões clínicas e técnicas fundamentais para esta escolha incluem: excelente calibração intrínseca de probabilidades (Brier Score = 0,021), comportamento estritamente monotônico e convexo (previsibilidade clínica), alta interpretabilidade e empate técnico no topo com os modelos baseados em árvores, sem o risco de overfitting.

5. Calibração de Limiares e Análise de Impacto dos Erros Clínicos

Em problemas de triagem oncológica, os custos e impactos dos erros de classificação são profundamente assimétricos. Um Falso Positivo (FP) gera ansiedade temporária e encaminhamento para exames complementares (mamografia diagnóstica ou ultrassom), com risco clínico mitigado. Já um Falso Negativo (FN) significa liberar inadvertidamente uma paciente com neoplasia ativa, postergando o tratamento e reduzindo drasticamente a sobrevida.

Por essa razão, a Guardiã AI rejeita o limiar arbitrário de 0,5 e adota uma política de estratificação em três faixas de risco com dois limiares calibrados:
• Limiar de Segurança (t_low = 0,09): Casos com probabilidade estimada < 0,09 são classificados como 'Baixo Risco' (rastreamento de rotina).
• Faixa Intermediária (0,09 ≤ P < 0,43): Casos classificados como 'Risco Intermediário', demandando reavaliação ou exames complementares.
• Limiar de Alto Risco (t_high = 0,43): Casos com probabilidade ≥ 0,43 são categorizados como 'Alto Risco', priorizados imediatamente para biópsia e mastologia.

Desempenho no Teste Cego (114 casos não vistos): Aplicado o limiar t_low = 0,09, o modelo obteve:
Recall = 97,6% (41 de 42 casos malignos detectados com segurança; apenas 1 FN);
Precisão = 85,4% | Acurácia = 93,0% | F1-Score = 91,1% | ROC-AUC = 0,996 | PR-AUC = 0,994 | Brier Score = 0,021.

6. Interpretabilidade e Explicabilidade Clínica com SHAP

Para assegurar transparência e confiança por parte da equipe médica, a predição é acompanhada de análise de explicabilidade baseada em SHAP (SHapley Additive exPlanations), fundamentada na teoria dos jogos cooperativos.

Para cada caso analisado, o sistema calcula os valores SHAP exatos e renderiza um gráfico de barras horizontal destacando as variáveis que mais influenciaram a predição (em vermelho para aumento de suspeita e azul para redução de suspeita).

A análise global confirma que as variáveis de maior peso clínico são: pior número de pontos côncavos (worst concave points), pior raio (worst radius), pior perímetro (worst perimeter), textura média (mean texture) e raio médio (mean radius). O sistema inclui uma legenda explicativa informando que variáveis morfologicamente correlacionadas dividem a contribuição SHAP.

7. Mecanismo de Recuperação Baseado em Protocolos (RAG)

A Guardiã AI incorpora um motor RAG (Retrieval-Augmented Generation) com base de conhecimento especializada armazenada em Markdown (data/kb/), contemplando 7 diretrizes oficiais:

1. 01_rastreamento_mama.md: Diretrizes do Ministério da Saúde e INCA para rastreamento mamográfico bienal (50 a 69 anos);
2. 02_sinais_alerta.md: Sinais e sintomas de alerta (nódulo palpável, descarga papilar sanguinolenta, retração cutânea);
3. 03_birads.md: Sistema de laudo e condutas da classificação BI-RADS (categorias 0 a 6);
4. 04_citologia_wdbc.md: Interpretação de dados de PAAF e citologia oncótica;
5. 05_limites_ia_governanca.md: Diretrizes de bioética, governança clínica e limites de atuação da IA;
6. 06_fluxo_encaminhamento.md: Linhas de cuidado e regulação de encaminhamentos no SUS;
7. 07_fatores_risco.md: Fatores de risco genéticos (mutações BRCA), idade e densidade mamária.

Os documentos foram segmentados em 29 trechos temáticos indexados por representação vetorial TF-IDF e métrica de similaridade por cosseno. O motor recupera os trechos mais relevantes (k=3), retornando obrigatoriamente o nome do arquivo, a seção e o escore de similaridade.

Avaliação do RAG: Foram submetidas 19 consultas clínicas de validação e 3 consultas fora do domínio (out-of-domain). O RAG alcançou Hit@1 = 100% e Hit@3 = 100%, rejeitando com sucesso consultas irrelevantes (limiar mínimo de similaridade = 0,08).

8. Integração com LLM e Guardrails de Segurança

A síntese contextualizada é gerada por Large Language Model (Claude 3.5 Sonnet via API Anthropic), utilizando um prompt estruturado contendo quatro blocos delimitados: dados do caso, predição do modelo, sinais de alerta extraídos do relato e trechos recuperados da base RAG.

Modo Offline e Resiliência: Para garantir disponibilidade ininterrupta mesmo em cenários de instabilidade de conexão ou ausência de chave de API, o sistema conta com um motor determinístico offline que sintetiza as mesmas evidências clínicas em texto estruturado por regras, servindo como fallback transparente.

Guardrails de Entrada (LGPD e Sanitização): Expressões regulares identificam e mascaram automaticamente dados pessoais sensíveis (CPF, e-mail e telefone) presentes no relato livre. Além disso, um classificador baseado em padrões heurísticos detecta e bloqueia tentativas de injeção de prompt.

Guardrails de Saída: O texto gerado é filtrado por expressões regulares que bloqueiam terminantemente afirmações de diagnóstico definitivo ('você tem câncer'), prescrições farmacológicas ('tome tamoxifeno 20mg') ou exclusões sumárias de doença. Caso uma infração seja detectada, o texto é substituído por mensagem segura e o evento é registrado na auditoria com anexação compulsória do disclaimer de responsabilidade médica.

9. Arquitetura e Orquestração do Pipeline com LangGraph

O pipeline principal da aplicação é orquestrado como um grafo de estados direcionado compilado com a biblioteca LangGraph, composto por 8 etapas coordenadas:
1. validate: Validação de tipos, intervalo dos 30 atributos citológicos, sanitização do relato livre e mascaramento de PII;
2. model: Execução do modelo de Machine Learning, cálculo de probabilidade e classificação na faixa de risco operacional;
3. findings: Extração de sinais de alerta clínicos (red flags) do relato (ex.: nódulo palpável, retração de pele);
4. retrieve: Consulta vetorial à base de conhecimento (RAG) buscando protocolos correspondentes aos achados;
5. generate: Geração da análise contextualizada em linguagem natural via LLM (ou fallback offline);
6. guard: Verificação de guardrails de saída, conformidade e garantia do disclaimer obrigatório;
7. persist: Gravação transacional do caso no banco de dados SQLite e inserção na trilha de auditoria encadeada;
8. human_review: Homologação da decisão médica final pelo profissional responsável (Human-in-the-Loop).

10. Segurança, Controle de Acesso (RBAC) e Trilha de Auditoria Encadeada

Controle de Acesso Baseado em Papéis (RBAC): O sistema define três perfis com permissões estritas:

• admin: Criação e gestão de usuários, execução de análises, visualização de histórico geral e auditoria;
• profissional: Execução de análises, interação com o assistente RAG, homologação da decisão médica final e visualização do próprio histórico;
• auditor: Acesso somente-leitura ao histórico consolidado e verificação de integridade da trilha de auditoria.

Mecanismos Criptográficos de Segurança: Senhas armazenadas com hash bcrypt (12 rounds); bloqueio temporário de conta por 15 minutos após 5 tentativas inválidas; sessões com expiração automática após 30 minutos de inatividade; tokens JWT (algoritmo HS256) na API REST; e pseudonimização de identificadores de casos por HMAC-SHA256.

Trilha de Auditoria com Hash Encadeado (SHA-256): Inspirada na tecnologia blockchain, a tabela de auditoria (audit) encadeia criptograficamente cada registro (h_i = SHA-256(h_{i-1} | timestamp | ator | ação | detalhe)). Caso qualquer registro anterior seja adulterado diretamente no banco de dados, a função verify_audit_chain() detecta a inconsistência e aponta exatamente o primeiro registro violado.

11. Homologação da Decisão Médica Final (Human-in-the-Loop)

Em estrito cumprimento à diretriz mandatória de que 'a decisão final sempre deverá permanecer com uma pessoa responsável pelo atendimento', o fluxo da Guardiã AI culmina obrigatoriamente na homologação médica.

Após a exibição da estimativa de risco, gráfico SHAP e protocolos RAG, o profissional dispõe de um formulário estruturado para registrar:
• Parecer Clínico: Concordância com alto risco / investigação prioritária; concordância com baixo risco / seguimento de rotina; discordância com reclassificação clínica; solicitação de exames complementares (USG/RNM/mamografia); ou conduta personalizada;
• Identificação Técnica: Registro profissional (CRM/COREN);
• Conduta Detalhada: Prescrição de exames, orientações ao paciente e justificativa clínica;
• Termo de Ciência e Responsabilidade: Checkbox obrigatória declarando que a decisão final permanece sob sua responsabilidade soberana.

A decisão é gravada de forma vinculada ao caso e registrada com evento HUMAN_REVIEW na trilha de auditoria encadeada. Na tela de histórico, o status é exibido como '✅ Concluído pelo médico' ou '⏳ Pendente de decisão médica', permitindo homologação posterior de casos pendentes.

12. Ambiente de Execução e Suíte de Testes Automatizados

A aplicação foi concebida para execução simples e flexível:
• Containerização: Dockerfile multi-estágio e docker-compose.yml orquestrando a interface web (Streamlit na porta 8501) e a API REST (FastAPI na porta 8000), com volumes persistentes para banco e chaves criptográficas;
• Execução Local: Ambiente virtual Python 3.12 com requirements.txt e script CLI administrativo para inicialização e gestão de usuários.

Validação Automatizada (pytest): O projeto conta com 14 testes automatizados cobrindo: validação de senhas fracas, proteção de hashes, bloqueio de tentativas sucessivas (lockout), ciclo de tokens JWT, controle RBAC, fluxo completo benigno/maligno, divergência entre modelo e relato clínico, sanitização de PII e injeção de prompt, guardrails de saída, cobertura do RAG, integridade e detecção de adulteração na auditoria, endpoints da API e homologação da decisão médica final. Todos os 14 testes executam com 100% de aprovação.

13. Limitações da Solução e Trabalhos Futuros

Limitações Reconhecidas:
1. Tamanho do Dataset: O conjunto UCI WDBC (569 casos) possui valor didático e histórico consolidado, mas não substitui a diversidade demográfica de bases populacionais contemporâneas;
2. Ausência de Validação Clínica Externa: O modelo não foi submetido a ensaio clínico multicêntrico e não pode ser utilizado para diagnóstico hospitalar sem validação regulatória;
3. Origem das Variáveis: As 30 medidas citológicas derivam de imagens digitalizadas de biópsia por agulha fina (PAAF), dependendo de operador especializado para aquisição prévia dos atributos celulares;
4. Infraestrutura de Persistência: O uso de SQLite local com segredo em arquivo é ideal para demonstração e avaliação, mas deve ser substituído por PostgreSQL e cofre de chaves (Key Vault) em ambiente de produção clínico.

Evoluções Futuras Recomendadas: Integração de visão computacional multimodal para extração direta de características a partir de imagens histopatológicas (conforme explorado na Fase 4); expansão da base de conhecimento RAG com embeddings neurais densos (BioBERT/ClinicalBERT); e integração via padrão HL7/FHIR com prontuários eletrônicos do paciente (PEP).

CONCLUSÃO

A Guardiã AI cumpre os objetivos pedagógicos, técnicos e éticos estabelecidos para o Tech Challenge Fase 5. O projeto demonstra na prática como transitar de modelos

analíticos isolados para uma plataforma integrada de apoio à decisão clínica, unindo com sucesso Dados, Machine Learning, SHAP, LLM, RAG, Governança e Aplicação.

A seleção da Regressão Logística calibrada com limiar operacional de segurança focado em Recall (97,6% no teste cego com apenas 1 falso negativo em 42 casos) assegura sensibilidade clínica máxima na triagem, enquanto a explicabilidade por SHAP e o embasamento documental do RAG em diretrizes do INCA/MS e BI-RADS conferem total transparência e suporte técnico ao profissional de saúde.

Sob a perspectiva de bioética e conformidade legal, a aplicação estabelece salvaguardas robustas: sanitização de dados sensíveis conforme a LGPD, guardrails contra alucinações e prescrições indevidas, e trilha de auditoria encadeada com SHA-256 à prova de adulterações. Acima de tudo, o sistema consagra a diretriz mandatória de que "a decisão final sempre deverá permanecer com uma pessoa responsável pelo atendimento", garantindo que a Inteligência Artificial permaneça como uma aliada do julgamento clínico humano em defesa da saúde e da vida da mulher.