

TECH CHALLENGE 03

IA para Devs

FIAP 2026

GRUPO 19

FIAP - POS TECH - IA para Devs

TECH CHALLENGE

TECH CHALLENGE 03

Grupo 19

Integrantes do Grupo

Cesar Melo Dutra - cesar.dutra@pcdf.df.gov.br

Fernando Ramos Etchepare - fernando.etchepare@pcdf.df.gov.br



Use a câmera do seu celular ou
acesse a página Git

<https://github.com/fetchepare/FIAP>



DESAFIO

Desenvolver um assistente virtual de atendimento médico especializado em saúde e segurança da mulher, utilizando *fine-tuning* de LLMs com dados específicos da área e implementando fluxos automatizados de decisão clínica.

OBJETIVO

Contexto

Após o sucesso na automação de análises de exames e otimização de modelos específicos para saúde da mulher, a rede de hospitais especializados quer avançar para um nível superior de personalização: criar um assistente virtual médico especializado, treinado com dados próprios da instituição, capaz de auxiliar nas condutas clínicas específicas para saúde feminina, responder dúvidas de profissionais especializados(as) e sugerir procedimentos com base nos protocolos internos de atendimento à mulher.

Além disso, a ideia é organizar fluxos de decisão automatizados e seguros, onde, por exemplo, ao receber informações sobre uma paciente, o sistema possa acionar diferentes etapas específicas, como verificar exames ginecológicos pendentes, sugerir tratamentos para questões reprodutivas, emitir alertas para casos suspeitos de violência doméstica, coordenar atendimento multidisciplinar (Ginecologista, psicóloga, assistente social) — tudo isso coordenado com LangChain e considerando as sensibilidades específicas do atendimento feminino.

ENTREGÁVEIS

Repositório Git:

Código-fonte especializado com:

- Pipeline de fine-tuning para dados de saúde da mulher;
- Integração com LangChain especializada;
- Fluxos do LangGraph para diferentes cenários clínicos;
- Dataset anonimizado ou exemplos de dados sintéticos específicos;
- Módulos de segurança e validação especializados.

LINKS

- Página GIT: <https://github.com/fetchepare/FIAP>
 - o Código Fonte Completo: techchallenge03.zip
 - o Relatório Técnico (estratégias, modelos, resultados e interpretação): TechChallenge03.PDF (este arquivo)
- Vídeo: https://youtu.be/_Y9aFAuTddk

RELATÓRIO TÉCNICO

Este documento descreve a arquitetura estruturada em uma Plataforma de IA especializada em assistência especializada Saúde da Mulher, bem como todos os fluxos clínicos, os mecanismos de segurança e o pipeline implementados no projeto.

O sistema foi estruturado com persistência de dados e com acesso via credenciais de acesso, desta forma:

- *Fine-tuning* especializado para protocolos clínicos femininos;
- Integração com LangChain para recuperação contextual de conhecimento médico;
- Fluxos clínicos com LangGraph;
- Uso de *datasets* anonimizados e dados sintéticos;
- Segurança conforme LGPD;
- Camadas de validação clínica e
- Auditoria.

1. Pipeline de Fine-Tuning para Dados de Saúde da Mulher

Projetado para especializar modelos LLM em protocolos clínicos voltados à saúde da mulher, nas seguintes áreas: ginecologia, obstetrícia, violência doméstica, rastreamento oncológico, saúde mental, endometriose, menopausa, pré-natal e puerpério.

O módulo condizente no projeto é o `finetuning/dataset_curadoria.py`

Arquitetura do Pipeline

```
A[Coleta de Protocolos Clínicos] --> B[Normalização de Dados]
B --> C[Anonimização LGPD]
C --> D[Balanceamento por Faixa Etária]
D --> E[Curadoria Médica]
E --> F[Conversão Alpaca / ChatML]
F --> G[Fine-Tuning LoRA / QLoRA]
G --> H[Validação Clínica]
H --> I[Deploy do Modelo]
```

Componentes Técnicos

1. Curadoria Especializada

O sistema utiliza um conjunto estruturado de protocolos médicos provenientes do Ministério da Saúde; da FEBRASGO do INCA, da OMS e da USPSTF.

O *dataset* inclui:

Categoria	Exemplos
Ginecologia	Endometriose, SOP, dismenorrea
Obstetrícia	Pré-eclâmpsia, diabetes gestacional
Oncologia	Rastreamento de colo uterino e mama
Violência	Triagem e acolhimento
Menopausa	Terapia hormonal e sintomas vasomotores

2. Anonimização de Dados

O *pipeline* faz o resumo (ou *hashing*) de identificadores, a remoção/descharacterização de dados pessoais, a tokenização de informações sensíveis e o mascaramento de dados clínicos, desta forma:

Campo Original	Campo Tratado
Maria da Silva	PACIENTE_HASH_001

Campo Original	Campo Tratado
CPF	REMOVIDO
Telefone	TOKEN_PRIVADO


3. Estrutura de Treinamento

O treinamento foi estruturado no formato LLM (modelo OLLAMA gemma2:2b , ChatML, LoRA (QLoRA)

Exemplo:

```
{
  "instruction": "Paciente com dor pélvica crônica e
dispareunia.",
  "input": "Mulher de 32 anos com sintomas há 3 anos.",
  "output": "Suspeita clínica compatível com endometriose.
Recomenda-se avaliação ginecológica especializada."
}
```

Gráfico — *Pipeline de Fine-Tuning*



2. Integração com LangChain Especializada

Objetivo

A camada LangChain foi utilizada para construir um *pipeline* RAG (*Retrieval-Augmented Generation*) especializado em protocolos clínicos femininos.

Arquivo relativo: langchain_rag/rag_pipeline.py

Arquitetura RAG

A[Paciente] --> B[API Clínica]
B --> C[LangChain RAG]
C --> D[Base Vetorial]
D --> E[Protocolos Médicos]
E --> C
C --> F[Resposta Explicável]

Características Técnicas

Base Vetorial Especializada

A solução utiliza base FAISS, busca semântica, recuperação contextual, evidência clínica e score de confiança.


Cada documento tem:

Campo	Descrição
source	Fonte médica/literatura
evidence_level	Nível de evidência
confidence	Confiabilidade
tags	Categorias

Funcionalidades Clínicas

Função	Objetivo
Triagem	Classificação inicial
Rastreamento	Prevenção oncológica
Alertas	Exames e risco clínico
Encaminhamento	Especialidades médicas
Orientações	Pós-consulta personalizada

Fluxo LangChain



3. Fluxos do LangGraph para Diferentes Cenários Clínicos

O LangGraph foi utilizado para modelar fluxos clínicos orientados por estado.

Arquivos que compõem essa característica estão na pasta langgraph_flows:

clinical_flows.py, advanced_flows.py, professional_qa_flow.py e unified_intake.py

Fluxos Implementados

1. Triagem Ginecológica

Fluxo responsável por:

- classificação de urgência;
- análise de sintomas;
- detecção de sinais de alerta;
- recomendação inicial.

2. Violência Doméstica

Fluxo para:

- detecção de risco;
- sigilo reforçado;
- encaminhamento protegido;
- protocolos de crise.

3. Fluxo Obstétrico

Responsável por:

- avaliação gestacional;
- estratificação de risco;
- acompanhamento pré-natal.

4. Rastreamento Preventivo

Automatiza os seguintes esquemas:

- prevenção oncológica;
- lembretes de exames;
- análise de periodicidade.

Arquitetura de Estados

```
[*] --> Admissão
Admissão --> Triagem
Triagem --> Emergências
Triagem --> Ambulatorial
Triagem --> Violência
Violência --> Protocolo Protegido
Ambulatorial --> Rastreamento
Rastreamento --> Encerramento
Emergências --> Encaminhamento Urgente
Encerramento --> [*]
```

Modelo de Estado Clínico

O sistema utiliza TypedDicts para persistência de contexto:

Estado	Finalidade
symptoms	Sintomas reportados
urgency_level	Nível de urgência
red_flags	Sinais críticos
recommended_exams	Exames sugeridos
risk_analysis	Análise probabilística

Gráfico — Fluxo Clínico



4. Dataset Anonimizado e Dados Sintéticos

Objetivo

Garantir:

- privacidade;
- conformidade LGPD;
- segurança clínica;
- treinamento ético.

Estratégia Utilizada

Dados Sintéticos

Foram utilizados exemplos simulados para a endometriose, o SOP, a menopausa, a violência doméstica e o rastreamento oncológico.

Tabela Exemplo

Campo	Exemplo
Idade	34
Sintoma	Dor pélvica crônica
Histórico	Infertilidade há 2 anos
Exame	US transvaginal

Campo	Exemplo
Hipótese	Endometriose

Pipeline de Anonimização

```

A[Dados Clínicos] --> B[Remoção de Identificadores]
B --> C[Hash Seguro]
C --> D[Tokenização]
D --> E[Dataset Seguro]

```

Técnicas Aplicadas

Técnica	Objetivo
Hashing SHA-256	Identificação indireta
Mascaramento	Privacidade
Generalização	Redução de granularidade
Pseudonimização	Proteção clínica

5. Módulos de Segurança e Validação Especializados

Objetivo

A plataforma implementa segurança multicamada para proteger:

- dados sensíveis;
- contexto clínico;
- histórico de violência;
- informações obstétricas.

Arquivos estão em pasta *security*: security.py e validator_explainability.py

5.1 Segurança Clínica

Recursos

Módulo	Função
RBAC	Controle de acesso por papel
AES-256-GCM	Criptografia de dados
PBKDF2	Derivação segura de chave
Auditoria	Rastreabilidade completa
Rate Limiting	Proteção contra abuso
LGPD	Conformidade regulatória

Controle de Acesso

Perfis identificados:

- Ginecologista;
- Obstetra;
- Enfermeiro(a);
- Psicólogo(a);
- Assistente social;
- Radiologista;
- Equipe de segurança.

Fluxo

```
A[Usuário] --> B[Autenticação]
B --> C[RBAC]
C --> D[Criptografia]
D --> E[Auditoria]
E --> F[Acesso Autorizado]
```

5.2 Validação Clínica do LLM

ResponseValidator

O módulo impede:

- diagnósticos definitivos;
- prescrições indevidas;
- recomendações inseguras;
- omissão de emergência clínica.

Regras Obrigatórias

NUNCA

- Prescreve medicamentos sem especialista;
- Diagnostica definitivamente;
- Ignora sinais críticos;
- Expõe dados sensíveis.

SEMPRE

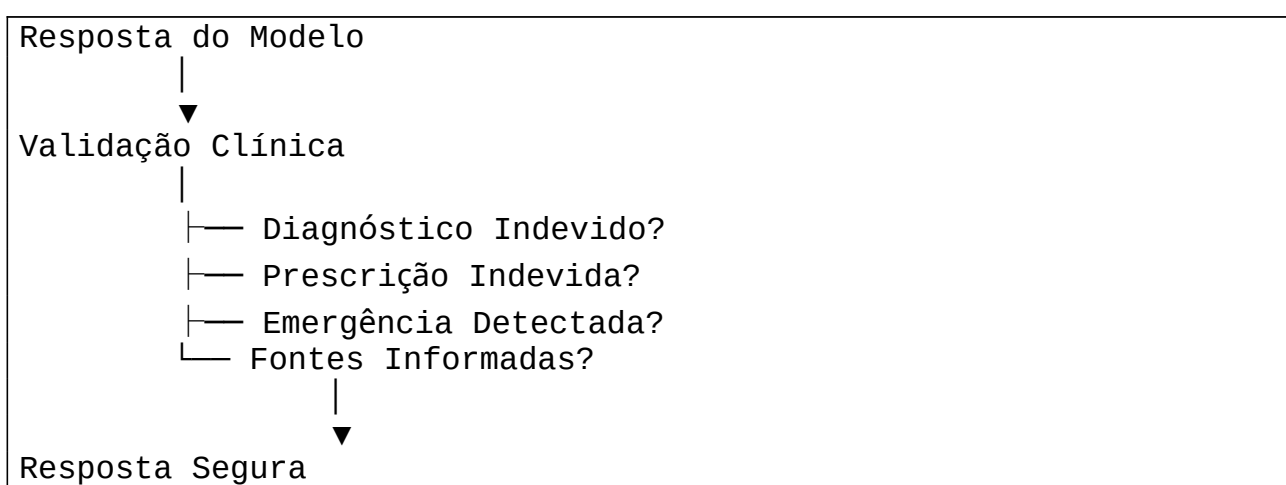
- Recomenda avaliação presencial;
- Encaminha violência doméstica;
- Exibe nível de confiança;
- Informa fontes clínicas.

Explainability Engine

Cada resposta tem:

Fonte	Diretriz clínica utilizada
Evidência	Grau científico
Confiança	Score probabilístico
Justificativa	Explicação do raciocínio

Gráfico — Validação do LLM



6. Arquitetura Consolidada da Plataforma

```
A[Paciente] --> B[Frontend/API]
B --> C[LangGraph]
C --> D[LangChain RAG]
D --> E[Base Vetorial]
D --> F[LLM Fine-Tuned]
F --> G[Validator]
G --> H[Security Layer]
H --> I[Resposta Explicável]
```

A seção Assistente final conta com Aba " Assistente Ollama" no frontend

Com o indicador de status verde

O sistema conta com um assistente LLM local integrado via Ollama. Vejam o indicador verde — o modelo LLaMA está rodando diretamente na máquina do hospital, sem conexão com servidores externos. Isso é fundamental para conformidade com a LGPD

7. Benefícios Técnicos da Arquitetura

Escalabilidade

Modularidade, independência de fluxos e estrutura e fácil integração hospitalar.

Segurança

Com criptografia, auditoria e controle de acesso

Especialização Clínica

Protocolos dedicados, evidências médicas contextuais e explicabilidade clínica.

Governança

Conformidade, rastreabilidade e controle de responsabilidade.

CONCLUSÃO

A solução implementa uma arquitetura de IA clínica especializada em saúde da mulher, que possui *fine-tuning* supervisionado, RAG contextual com LangChain, Orquestração clínica via LangGraph, Segurança multicamada, Explicabilidade clínica e Validação rigorosa de respostas.

O modelo demonstra aderência a padrões de IA aplicada à saúde, preservando requisitos críticos de segurança do paciente, ética médica, privacidade, governança, transparência de fluxos.